

Homework 2

Lecturer: Xiangyu Chang

Scribe: 赵敬业

Edited by: Junbo Hao

1 HW 1

1.1 问题重述

在项目组合管理示例中，我们将操作问题表示为：

$$\max_{\mathbf{x}} \mathbb{E}(R) - \lambda \text{Var}(R) \quad (1)$$

$$\text{s.t. } x_i \geq 0, i = 1 \dots, n \quad (2)$$

$$\sum_{i=1}^n x_i = 1 \quad (3)$$

其中 $\mathbb{E}(R)$ 是 R 的预期收益率； $\text{Var}(R)$ 是 R 的方差； $\lambda > 0$ 被称为风险厌恶参数，用于平衡投资风险和预期收益。我们进一步假设 $\mathbf{r} = (r_1, \dots, r_n)^\top$ 是一个期望为 $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^\top$ 的随机向量，其协方差为 Σ 。

请证明原优化问题等价于：

$$\max_{\mathbf{x}} \boldsymbol{\mu}^\top \mathbf{x} - \lambda \mathbf{x}^\top \Sigma \mathbf{x}, \quad (4)$$

$$\text{s.t. } x_i \geq 0, i = 1 \dots, n, \quad (5)$$

$$\sum_{i=1}^n x_i = 1 \quad (6)$$

1.2 证明

$$\mathbb{E}(r) = \boldsymbol{\mu} \quad (7)$$

$$R = \sum_{i=1}^n (r_{it} * x_i) \quad (8)$$

$$\mathbb{E}(R) = \mathbb{E}\left(\sum_{i=1}^n (r_{it} * x_i)\right) = \sum_{i=1}^n (\mathbb{E}(r_{it} * x_i)) = \sum_{i=1}^n (x_i * \mathbb{E}(r_{it})) = \sum_{i=1}^n (x_i * \mu_i) = \boldsymbol{\mu}^\top \mathbf{x} \quad (9)$$

$$\text{Var}(R) = \text{Var}\left(\sum_{i=1}^n (r_{it} * x_i)\right) = \sum_{i=1}^n (\text{Var}(r_{it} * x_i)) = \sum_{i=1}^n x_i^2 (\text{Var}(r_{it})) = \sum_{i=1}^n x_i^2 \sigma_i^2 = \sum_{i=1}^n x_i \sigma_i x_i = \mathbf{x}^\top \Sigma \mathbf{x}. \quad (10)$$

QED

2 HW 2

2.1 问题重述

泊松回归：假设现在 b_i 是计数值， \mathbf{a}_i 是 \mathbb{R}^p 的一些预测值。设 λ_i 为某一时间段内的预期事件数，即得：

$$P(b_i | \lambda_i) = \frac{e^{-\lambda_i} \lambda_i^{b_i}}{b_i!} \quad (11)$$

以广义线性模型为例，推导出下面的最优化形式来表示简单的泊松回归：

$$\min_{\mathbf{x}} \sum_{i=1}^m \exp(\langle \mathbf{a}_i, \mathbf{x} \rangle) - \langle \mathbf{b}, A\mathbf{x} \rangle. \quad (12)$$

2.2 证明

假设 $\ln \lambda_i = \langle \mathbf{a}_i, \mathbf{x} \rangle$ 该模型使用最大似然估计，估计公式如下：

$$\max_{\lambda} \prod_{i=1}^m \frac{e^{-\lambda_i} \lambda_i^{b_i}}{b_i!} \quad (13)$$

$$\Leftrightarrow \max_{\lambda} \ln \prod_{i=1}^m \frac{e^{-\lambda_i} \lambda_i^{b_i}}{b_i!} \quad (14)$$

$$= \max_{\lambda} \sum_{i=1}^m \ln \frac{e^{-\lambda_i} \lambda_i^{b_i}}{b_i!} \quad (15)$$

$$\Leftrightarrow \max_{\lambda} \sum_{i=1}^m (-\lambda_i) + b_i \ln(\lambda_i) \quad (16)$$

$$\Leftrightarrow \min_{\lambda} \sum_{i=1}^m (\lambda_i) - b_i \ln(\lambda_i). \quad (17)$$

带入 $\ln \lambda_i = \langle \mathbf{a}_i, \mathbf{x} \rangle$ ，得

$$\min_{\mathbf{x}} \sum_{i=1}^m (\exp \langle \mathbf{a}_i, \mathbf{x} \rangle) - b_i \langle \mathbf{a}_i, \mathbf{x} \rangle. \quad (18)$$

注意到：

$$\sum_{i=1}^m b_i \langle \mathbf{a}_i, \mathbf{x} \rangle = \langle \mathbf{b}, A\mathbf{x} \rangle. \quad (19)$$

原式 =

$$\min_{\mathbf{x}} \sum_{i=1}^m (\exp \langle \mathbf{a}_i, \mathbf{x} \rangle) - \langle \mathbf{b}, A\mathbf{x} \rangle. \quad (20)$$

QED

3 HW 3

3.1 问题重述

设

$$f(\mathbf{x}) = \sum_{i=1}^m \log(1 + \exp(\langle \mathbf{a}_i, \mathbf{x} \rangle)) - \langle \mathbf{b}, A\mathbf{x} \rangle \quad (21)$$

为逻辑回归的目标函数，请计算梯度和 $f(\mathbf{x})$ 的 Hessian 矩阵。

3.2 证明

$$f(\mathbf{x}) = \sum_{i=1}^m \log(1 + \exp(\langle \mathbf{a}_i, \mathbf{x} \rangle)) - \langle \mathbf{b}, A\mathbf{x} \rangle. \quad (22)$$

假设：

$$z_i = \langle \mathbf{a}_i, \mathbf{x} \rangle g(z_i) = \sum_{i=1}^m \log(1 + \exp(z_i)) - b_i z_i \quad (23)$$

$$G(z) = \sum_{i=1}^m g(z_i) \quad (24)$$

$$\nabla G(z)_i = \left(\frac{\exp(z_i)}{1 + \exp(z_i)} - b_i \right). \quad (25)$$

由通用公式：

$$\nabla f(x) = A^\top \nabla G(z) = (a_1, a_2, \dots, a_m) \begin{pmatrix} \frac{\exp(\langle \mathbf{a}_1, \mathbf{x} \rangle)}{1 + \exp(\langle \mathbf{a}_1, \mathbf{x} \rangle)} - b_1 \\ \frac{\exp(\langle \mathbf{a}_2, \mathbf{x} \rangle)}{1 + \exp(\langle \mathbf{a}_2, \mathbf{x} \rangle)} - b_2 \\ \vdots \\ \frac{\exp(\langle \mathbf{a}_m, \mathbf{x} \rangle)}{1 + \exp(\langle \mathbf{a}_m, \mathbf{x} \rangle)} - b_m \end{pmatrix}. \quad (26)$$

其中第 i 个

$$\frac{\partial f(x)}{\partial x} = \sum_{j=1}^m a_{ij} \left(\frac{\exp(\langle \mathbf{a}_j, \mathbf{x} \rangle)}{1 + \exp(\langle \mathbf{a}_j, \mathbf{x} \rangle)} - b_j \right) = \sum_{j=1}^m a_{ij} \frac{\exp(\langle \mathbf{a}_j, \mathbf{x} \rangle)}{1 + \exp(\langle \mathbf{a}_j, \mathbf{x} \rangle)} - \sum_{j=1}^m a_{ij} b_j. \quad (27)$$

以上就是其梯度，下面计算海森矩阵：

假设：

$$t_i = \langle \mathbf{a}_i, \mathbf{x} \rangle \phi(t_i) = \sum_{j=1}^m a_{ij} \left(\frac{\exp(t_j)}{1 + \exp(t_j)} - b_j \right) \quad (28)$$

$$\Phi(t) = \sum_{j=1}^m \phi(t_j). \quad (29)$$

由通用公式，得：

$$\nabla^2 f(x)_i = A^\top \nabla \Phi(t) = (a_1, a_2, \dots, a_m) \begin{pmatrix} a_{i1} \frac{\exp(\langle \mathbf{a}_1, \mathbf{x} \rangle)}{(1 + \exp(\langle \mathbf{a}_1, \mathbf{x} \rangle))^2} \\ a_{i2} \frac{\exp(\langle \mathbf{a}_2, \mathbf{x} \rangle)}{(1 + \exp(\langle \mathbf{a}_2, \mathbf{x} \rangle))^2} \\ \vdots \\ a_{im} \frac{\exp(\langle \mathbf{a}_m, \mathbf{x} \rangle)}{(1 + \exp(\langle \mathbf{a}_m, \mathbf{x} \rangle))^2} \end{pmatrix}. \quad (30)$$

特别地：

$$\frac{\partial^2 f(x)}{\partial x_i \partial x_j} = \sum_{j=1}^m a_{ij}^2 \left(\frac{\exp(\langle \mathbf{a}_j, \mathbf{x} \rangle)}{(1 + \exp(\langle \mathbf{a}_j, \mathbf{x} \rangle))^2} \right). \quad (31)$$

4 HW 4

4.1 问题重述

考虑函数 $f(x) = x_1^2 + x_2^2, x = (x_1, x_2) \in \mathbb{R}^2$ ，以及迭代点列 $x^k = (1 + \frac{1}{2^k})(\cos k, \sin k)^\top, k = 1, 2, \dots$ ，请说明：

(a) $\{f(x^{k+1})\}$ 是否收敛？若收敛，给出 Q-收敛速度；

(b) $\{x^{k+1}\}$ 是否收敛？若收敛，给出 Q-收敛速度。

4.2 解

(a) 收敛

$$\lim_{k \rightarrow \infty} \frac{\|f(x^{k+1}) - f(x^*)\|}{\|f(x^k) - f(x^*)\|} \quad (32)$$

$$= \frac{\left\| \left(\left(1 + \frac{1}{2^{k+1}}\right) \cos(k+1) \right)^2 + \left(\left(1 + \frac{1}{2^{k+1}}\right) \sin(k+1) \right)^2 - 1 \right\|}{\left\| \left(1 + \frac{1}{2^k}\right) \cos^2 k + \left(1 + \frac{1}{2^{k+1}}\right) \sin^2 k - 1 \right\|} \quad (33)$$

$$= \frac{\left(1 + \frac{1}{2^{k+1}}\right)^2 - 1}{\left(1 + \frac{1}{2^k}\right)^2 - 1} = \frac{2 + \frac{1}{2^{k+1}}}{2 + \frac{1}{2^k}} \frac{1}{2} = \frac{1}{2}. \quad (34)$$

收敛速度 $\frac{1}{2}$

(b) 不收敛

$$\lim_{k \rightarrow \infty} x^k = (\cos k, \sin k)^\top \quad (35)$$

不收敛

5 HW 5

5.1 问题重述

请通过 Jacobi 和 Gauss-Seidel 迭代算法求解以下方程, 并讨论这两个方程的收敛条件:

$$Ax = b \quad (36)$$

$$(a) \ A = \begin{pmatrix} 1 & 2 & 1 \\ 3 & 8 & 1 \\ 0 & 4 & 1 \end{pmatrix} \text{ and } \mathbf{b} = (2, 12, 2)^\top.$$

$$(b) \ A = \begin{pmatrix} 8 & -3 & 2 \\ 4 & 11 & -1 \\ 2 & 1 & 4 \end{pmatrix} \text{ and } \mathbf{b} = (20, 33, 12)^\top.$$

5.2 证明

使用 python 代码

为主文档简洁起见, 请移步附录观看源代码及其求解结果。出现了如下结果:

当使用 jacobi 迭代时, 第一问不收敛, 第二问收敛, 当使用 gauss 迭代时, 均收敛至 x^*

经过计算, 发现雅各比迭代在第一问中的谱半径为 $1.5 > 1$, 不能保证它收敛, 具体还需进一步讨论; 第二问谱半径 $0.3592 < 1$, 收敛;

而高斯迭代第一问谱半径 0.25 , 第二问谱半径 0.13 均小于 1 , 故收敛。

参考文献