

Homework 3

Lecturer: Xiangyu Chang

Scribe: 赵敬业

1 HW 1

1.1 问题重述

(1) 已知 $A = \begin{bmatrix} 1 & 1 & 2 \\ 2 & 1 & 3 \\ 3 & 1 & 4 \end{bmatrix}$, 请计算列空间 $C(A)$ 和零空间 $N(A)$.

(2) 证明对任意 $A \in \mathbb{R}^{m \times n}$, 有

$$C(A) \perp N(A^T)$$

1.2 解 (1)

$$A = \begin{bmatrix} 1, 1, 2 \\ 2, 1, 3 \\ 3, 1, 4 \end{bmatrix}$$

$$\Rightarrow \begin{bmatrix} 1, 0, 0 \\ 2, -1, 0 \\ 3, -2, 0 \end{bmatrix} = U.$$

则显然

$$C(A) = \{y : y = Ax, \forall x \in \mathbb{R}^n\}$$

$$\Rightarrow C(A) = \text{span}\left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \begin{bmatrix} 0 \\ -1 \\ -2 \end{bmatrix} \right\}$$

$$N(A) = \{x \in \mathbb{R}^n : Ax = 0\} = \text{span}\left\{ \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix} \right\}$$

1.3 证明 (2)

$$\begin{aligned}\forall \vec{y}_1 &\in C(A), \\ \forall \vec{x}_2 &\in N(A^T)\end{aligned}$$

下面分情况讨论:

情况一 $r(A) = 0$:

$$\begin{aligned}r(y) &= 0, \text{ then} \\ \langle y_1, x_2 \rangle &= 0\end{aligned}$$

显然成立,

情况二: $r(A) > 0$:

$$\begin{aligned}\langle A, x_2 \rangle &= 0, \text{ means, } A^T x_2 = 0 \\ &\Leftrightarrow x_1^T A^T x_2 = 0 \\ &\Leftrightarrow (Ax_1)^T x_2 = 0 \\ &\Leftrightarrow \langle y_1, x_2 \rangle = 0\end{aligned}$$

综合以上两种情况, 得证

2 HW 2

2.1 问题重述

- (1) 证明 ℓ_0 范数不是向量范数
- (2) 证明 $\sigma_1 = \sup_{\|\mathbf{x}\|_2=1} \|A\mathbf{x}\|_2$, 其中 σ_1 是 A 的最大奇异值
- (3) $\|AB\|_F \leq \|A\|_2 \|B\|_F$ 对任何 $A \in \mathbb{R}^{m \times n}, B \in \mathbb{R}^{n \times p}$ 成立

2.2 证明 (1)

$$\|2x_0\| \neq 2 \times \|x_0\|$$

不满足齐性要求, 得证

2.3 证明 (2)

Lemma : $\forall U \in \text{Orthogonal matrix} \Rightarrow \|Ux\|_2 = \|x\|_2$

Proof : $\forall U \in \text{Orthogonal matrix}$:

$$\|Ux\|_2 = \left\| \sum_j u_j x_j \right\|_2 = \left(\sum_i \left(\sum_j u_{ij} x_j \right)^2 \right)^{\frac{1}{2}} = \left(\sum_i (\langle u_i, x \rangle)^2 \right)^{\frac{1}{2}}$$

因为这是正交矩阵, 故可以取 $k_i, i = 1, 2, \dots, n$, 使得 $x = \sum_{j=1}^n k_j u_j$, 从而原式有:

$$\begin{aligned} &= \left(\sum_i \left(\left\langle u_i, \sum_{j=1}^n k_j u_j \right\rangle \right)^2 \right)^{\frac{1}{2}} \\ &= \left(\sum_i (\langle u_i, k_i u_i \rangle)^2 \right)^{\frac{1}{2}} \\ &= \left(\sum_i (k_i \langle u_i, u_i \rangle)^2 \right)^{\frac{1}{2}} \\ &= \left(\sum_i (k_i \|u_i\|_2^2)^2 \right)^{\frac{1}{2}} = \left(\sum_i (k_i)^2 \right)^{\frac{1}{2}} = \|x\|_2 \\ \text{for : } \|x\|_2^2 &= \left\| \left(\sum_{j=1}^n k_j u_j \right) \right\|_2^2 = \left(\sum_{i=1}^n k_i^2 \right) \end{aligned}$$

lemma 得证

对 A 进行奇异值分解: $A = U \Sigma V$

$$\|Ax\|_2 = \|U \Sigma V x\|_2$$

$$(\text{lemma}) = \|\Sigma V x\|_2$$

令: $Vx = y$

$$\begin{aligned} &= \|\Sigma y\|_2 \leq \left(\sum_i \left(\sum_j \sigma_{ij}^2 y_j^2 \right) \right)^{\frac{1}{2}} \\ &= \left(\sum_j \left(\sum_i \sigma_{ij}^2 y_j^2 \right) \right)^{\frac{1}{2}} \leq \sigma_1 \left(\sum_j y_j^2 \right)^{\frac{1}{2}} = \sigma_1 \|y\|_2 \\ &= \sigma_1 \|x\|_2 = \sigma_1 \end{aligned}$$

当 $x = V_1$ 时, ‘=’ 成立

QED

2.4 证明 (3)

Lemma : $\forall V \in \text{Orthogonal matrix} \Rightarrow \|VB\|_F = \|B\|_F \quad \text{for} : V \in R^{n \times n} B \in R^{n \times p}$

$$\begin{aligned} \text{Proof} : \|VB\|_F &= \left(\sum_{i=1}^n \sum_{j=1}^p \left(\sum_{k=1}^n v_{ik} b_{kj} \right)^2 \right)^{\frac{1}{2}} = \left(\sum_{i=1}^n \sum_{j=1}^p (\langle v_i, b_j \rangle)^2 \right)^{\frac{1}{2}} \\ &= \left(\sum_{j=1}^p \|b_j\|_2^2 \right)^{\frac{1}{2}} = \|B\|_F \end{aligned}$$

Lemma QED

分解奇异值 $A = U\Sigma V$

$$\|AB\|_F = \|U\Sigma VB\|_F = \|\Sigma VB\|_F$$

Suppose : $VB = C \quad \Sigma \in R^{m \times n} \quad C \in R^{n \times p} \quad \sigma_i, i = 1, 2, \dots, \text{rank}(\Sigma)$

$$\begin{aligned} &= \|\Sigma C\|_F = \left(\sum_{i=1}^m \sum_{j=1}^p \sum_{k=1}^n (\sigma_{ik} C_{kj})^2 \right)^{\frac{1}{2}} \\ &= \left(\sum_{i=1}^m \sum_{j=1}^p (\sigma_{ii}^2 C_{ij}^2) \right)^{\frac{1}{2}} \leq \left(\sum_{i=1}^m \sum_{j=1}^p (\sigma_1^2 C_{ij}^2) \right)^{\frac{1}{2}} \\ &= \sigma_1 \left(\sum_{i=1}^m \sum_{j=1}^p C_{ij}^2 \right)^{\frac{1}{2}} \\ &= \|A\|_2 \|C\|_F = \|A\|_2 \|B\|_F \end{aligned}$$

3 HW 3

3.1 问题重述

已知

$$f(\mathbf{x}) = \sum_{i=1}^m \log(1 + \exp(\langle \mathbf{a}_i, \mathbf{x} \rangle)) - \langle \mathbf{b}, A\mathbf{x} \rangle$$

是 Logistic 回归的目标函数, 那么:

- (1) 请证明: $f(\mathbf{x})$ 是 β 是平滑的;
- (2) 写下 Logistic 回归的梯度下降算法的迭代公式.

3.2 证明 (1)

$$\nabla f(x) = \sum_{i=1}^m \left(\frac{\exp \langle a_i, x \rangle}{1 + \exp \langle a_i, x \rangle} - b_i \right) a_i^T$$

假设:

$$\begin{aligned} z_i &= \langle \mathbf{a}_i, \mathbf{x} \rangle, g(z_i) = \sum_{i=1}^m \log(1 + \exp(z_i)) - b_i z_i \\ G(z) &= \sum_{i=1}^m g(z_i) \\ \nabla G(z)_i &= \left(\frac{\exp(z_i)}{1 + \exp(z_i)} - b_i \right) \end{aligned}$$

由通用公式:

$$\nabla f(x) = A^T \nabla G(z) = (a_1, a_2, \dots, a_m) \begin{pmatrix} \frac{\exp(\langle \mathbf{a}_1, \mathbf{x} \rangle)}{1 + \exp(\langle \mathbf{a}_1, \mathbf{x} \rangle)} - b_1 \\ \frac{\exp(\langle \mathbf{a}_2, \mathbf{x} \rangle)}{1 + \exp(\langle \mathbf{a}_2, \mathbf{x} \rangle)} - b_2 \\ \vdots \\ \frac{\exp(\langle \mathbf{a}_m, \mathbf{x} \rangle)}{1 + \exp(\langle \mathbf{a}_m, \mathbf{x} \rangle)} - b_m \end{pmatrix}.$$

其中第 i 个

$$\frac{\partial f(x)}{\partial x} = \sum_{j=1}^m a_{ij} \left(\frac{\exp(\langle \mathbf{a}_j, \mathbf{x} \rangle)}{1 + \exp(\langle \mathbf{a}_j, \mathbf{x} \rangle)} - b_j \right) = \sum_{j=1}^m a_{ij} \frac{\exp(\langle \mathbf{a}_j, \mathbf{x} \rangle)}{1 + \exp(\langle \mathbf{a}_j, \mathbf{x} \rangle)} - \sum_{j=1}^m a_{ij} b_j.$$

以上就是其梯度，下面计算海森矩阵:

假设:

$$\begin{aligned} t_i &= \langle \mathbf{a}_i, \mathbf{x} \rangle \phi(t_i) = \sum_{j=1}^m a_{ij} \left(\frac{\exp(t_j)}{1 + \exp(t_j)} - b_j \right) \\ \Phi(t) &= \sum_{j=1}^m \phi(t_j). \end{aligned}$$

由通用公式，得:

$$\nabla^2 f(x)_i = A^\top \nabla \Phi(t) = (a_1, a_2, \dots, a_m) \begin{pmatrix} a_1^\top \frac{\exp(\langle \mathbf{a}_1, \mathbf{x} \rangle)}{(1 + \exp(\langle \mathbf{a}_1, \mathbf{x} \rangle))^2} \\ a_2^\top \frac{\exp(\langle \mathbf{a}_2, \mathbf{x} \rangle)}{(1 + \exp(\langle \mathbf{a}_2, \mathbf{x} \rangle))^2} \\ \vdots \\ a_m^\top \frac{\exp(\langle \mathbf{a}_m, \mathbf{x} \rangle)}{(1 + \exp(\langle \mathbf{a}_m, \mathbf{x} \rangle))^2} \end{pmatrix}.$$

$$\nabla^2 f(x) = \begin{pmatrix} \frac{\exp(\langle \mathbf{a}_1, \mathbf{x} \rangle)}{(1 + \exp(\langle \mathbf{a}_1, \mathbf{x} \rangle))^2}, 0, \dots, 0 \\ 0, \frac{\exp(\langle \mathbf{a}_2, \mathbf{x} \rangle)}{(1 + \exp(\langle \mathbf{a}_2, \mathbf{x} \rangle))^2}, \dots, 0 \\ \vdots, \ddots, \vdots \\ 0, 0, \dots, \frac{\exp(\langle \mathbf{a}_m, \mathbf{x} \rangle)}{(1 + \exp(\langle \mathbf{a}_m, \mathbf{x} \rangle))^2} \end{pmatrix} A^\top A.$$

特别地:

$$\frac{\partial^2 f(x)}{\partial x_i \partial x_j} = \sum_{j=1}^m a_{ij}^2 \left(\frac{\exp(\langle \mathbf{a}_j, \mathbf{x} \rangle)}{(1 + \exp(\langle \mathbf{a}_j, \mathbf{x} \rangle))^2} \right)$$

下面计算 $\nabla^2 f(x)$ 的二范数:

首先注意到 $\nabla^2 f(x)$ 最左边的矩阵可以表示为 I 中每个矩阵元素乘以一个小于1的数的初等矩阵 E

$$\|\nabla^2 f(x)\|_2 = \|EA^\top A\|_2 \leq \|E\|_2 \|A^\top A\|_2 \leq \|A^\top A\|_2 = \sigma_{max}^2.$$

因此, $f(x)$ 是 $\sigma_{max}^2 - smooth$ 函数, 令 $\sigma_{max}^2 = \sigma_1^2$,

写作: $\sigma_1^2 - smooth$

3.3 解 (2)

1: 输入: 给出初值点 $x^0 \in dom(f)$, 容忍度 ϵ 和 $t = 0$

2: while $f(x^t) \geq \epsilon$ do

$$3: x^{t+1} = x^t - \frac{1}{\sigma_1^2} (a_1, a_2, \dots, a_m) \begin{pmatrix} \frac{\exp(\langle \mathbf{a}_1, \mathbf{x} \rangle)}{1 + \exp(\langle \mathbf{a}_1, \mathbf{x} \rangle)} - b_1 \\ \frac{\exp(\langle \mathbf{a}_2, \mathbf{x} \rangle)}{1 + \exp(\langle \mathbf{a}_2, \mathbf{x} \rangle)} - b_2 \\ \vdots \\ \frac{\exp(\langle \mathbf{a}_m, \mathbf{x} \rangle)}{1 + \exp(\langle \mathbf{a}_m, \mathbf{x} \rangle)} - b_m \end{pmatrix}, t = t + 1$$

4: end while

5: 输出: x^T , 即循环最后的 x^{t+1} .

4 HW 4

4.1 问题重述

(1) $C \subseteq \mathbb{R}^n$ 是一个凸集, $\mathbf{x}_1, \dots, \mathbf{x}_k \in C$, 取 $\theta_1, \theta_2, \dots, \theta_k \in \mathbb{R}$ 满足 $\theta_i \geq 0, \sum_i \theta_i = 1$.

试证明 $\theta_1 \mathbf{x}_1 + \theta_2 \mathbf{x}_2 + \cdots + \theta_k \mathbf{x}_k \in C$.

(2) 证明椭球体 $E(\mathbf{x}_c) = \left\{ \mathbf{x} \mid (\mathbf{x} - \mathbf{x}_c)^\top A (\mathbf{x} - \mathbf{x}_c) \leq 1, A \in \mathcal{S}_{++}^n \right\}$ 是一个凸集.

(3) 设 f 是一个凸函数, 并且表示该集合包含所有可以达到 f 的全局最小值的点, 即 G 请证明 G 是凸的.

4.2 证明 (1)

C 为凸集则 $\forall x_i, x_j \in C$ 满足:

$$\theta_i x_i + (1 - \theta_i) x_j \in C$$

$$\text{Suppose : } x_i = x_{k-1}, x_j = x_k$$

$$\Rightarrow x_{k-1}^* = \frac{\theta_{k-1}}{1 - \theta_1 - \theta_2 - \cdots - \theta_{k-2}} x_{k-1} + \frac{\theta_k}{1 - \theta_1 - \theta_2 - \cdots - \theta_{k-2}} x_k \in C$$

$$\Rightarrow x_{k-2}^* = \frac{\theta_{k-2}}{1 - \theta_1 - \theta_2 - \cdots - \theta_{k-3}} x_{k-2} + \frac{\theta_{k-1} + \theta_k}{1 - \theta_1 - \theta_2 - \cdots - \theta_{k-3}} x_{k-1}^* \in C$$

...

$$\Rightarrow x_2^* = \frac{\theta_2}{1 - \theta_1} x_2 + \frac{1 - \theta_1 - \theta_2}{1 - \theta_1} x_k^* \in C \Rightarrow \theta_1 x_1 + (1 - \theta_1) x_2^* \in C$$

其中 $\theta_1 x_1 + (1 - \theta_1) x_2^* \in C$ 代入 $x_2^*, x_3^*, \dots, x_{k-1}^*$ 可以得到: $\theta_1 \mathbf{x}_1 + \theta_2 \mathbf{x}_2 + \cdots + \theta_k \mathbf{x}_k \in C$.

4.3 证明 (2)

$$\forall \theta_i \neq 0$$

$$\forall x_1, x_2 \in E(x_c) \quad , \forall \beta \in (0, 1)$$

也就是: $(x_1 - x_c)^\top A x_1 - x_c \leq 1; (x_2 - x_c)^\top A x_2 - x_c \leq 1$

$$\begin{aligned} & (\theta x_1 + (1 - \theta) x_2 - x_c)^\top A (\theta x_1 + (1 - \theta) x_2 - x_c) \\ &= (\theta(x_1 - x_c) + (1 - \theta)(x_2 - x_c))^\top A (\theta(x_1 - x_c) + (1 - \theta)(x_2 - x_c)) \\ &= \theta^2 (x_1 - x_c)^\top A (x_1 - x_c) + \theta(1 - \theta)(x_1 - x_c)^\top A (x_2 - x_c) + \\ & \quad \theta(1 - \theta)(x_2 - x_c)^\top A (x_1 - x_c) + (1 - \theta)^2 (x_2 - x_c)^\top A (x_2 - x_c) \\ &< \theta^2 + (1 - \theta)^2 + \theta(1 - \theta)(x_1 - x_c)^\top A (x_2 - x_c) + (1 - \theta)\theta(x_2 - x_c)^\top A (x_1 - x_c) \\ & \quad = \theta^2 + (1 - \theta)^2 + \\ & \quad \theta(1 - \theta) \left((x_1 - x_2)^\top A (x_2 - x_c) + (x_2 - x_1)^\top A (x_1 - x_2) + (x_1 - x_2)^\top A (x_1 - x_c) + (x_2 - x_c)^\top A (x_2 - x_c) \right) \\ & \leq \theta^2 + (1 - \theta)^2 + 2\theta(1 - \theta) = 1 \end{aligned}$$

QED

4.4 证明 (3)

$$\forall x_1 \in G, x_2 \in G \text{ which means : } \forall x \in \text{dom}(f), f(x) \geq f(x_1), f(x) \geq f(x_2) \quad \text{and} \quad f(x_1) = f(x_2)$$

$$f(x_1) \leq f(\theta x_1 + (1 - \theta)x_2) \leq \theta f(x_1) + (1 - \theta)f(x_2) = f(x_1)$$

则: $f(\theta x_1 + (1 - \theta)x_2) = f(x_1)$, $\theta x_1 + (1 - \theta)x_2 \in G$
QED

5 HW5

5.1 问题重述

- (1) 设 \mathbf{a} 和 \mathbf{b} 是 \mathbb{R}^n 中的不同点. 表示比 \mathbf{b} 更接近的所有点的集合是半空间.
- (2) 两个平行超平面 $\{\mathbf{x} \mid \mathbf{a}^\top \mathbf{x} = b_1\}$ 和 $\{\mathbf{x} \mid \mathbf{a}^\top \mathbf{x} = b_2\}$ 之间的距离是多少?

5.2 证明 (1)

首先: $\exists x_0 = \frac{1}{2}\mathbf{a} + \frac{1}{2}\mathbf{b}$ 满足 $\|x_0 - \mathbf{a}\|_2 = \|x_0 - \mathbf{b}\|_2$
且: $\forall x$ 满足

$$\begin{aligned} \langle x - x_0, \mathbf{b} - \mathbf{a} \rangle &= 0 \Leftrightarrow x^\top \mathbf{b} - x^\top \mathbf{a} - \frac{1}{2} \mathbf{b}^\top \mathbf{b} + \frac{1}{2} \mathbf{a}^\top \mathbf{a} = 0 \\ &\Leftrightarrow \frac{1}{2} \mathbf{b}^\top \mathbf{b} - x^\top \mathbf{b} + \frac{1}{2} x^\top x = \frac{1}{2} \mathbf{a}^\top \mathbf{a} - x^\top \mathbf{a} + \frac{1}{2} x^\top x \\ &\Leftrightarrow \langle \mathbf{b} - x, \mathbf{b} - x \rangle = \langle \mathbf{a} - x, \mathbf{a} - x \rangle \Leftrightarrow d_1 = d_2 \end{aligned}$$

$$\begin{aligned} \text{Suppose : } d_1 &= \|\vec{x} - \vec{a}\|_2 = \sqrt{\langle \vec{x}, \vec{a} \rangle} \quad d_2 = \|\vec{x} - \vec{b}\|_2 = \sqrt{\langle \vec{x}, \vec{b} \rangle} \\ d_1 < d_2 &\Leftrightarrow \langle x - \mathbf{a}, x - \mathbf{a} \rangle < \langle x - \mathbf{b}, x - \mathbf{b} \rangle \Leftrightarrow \frac{1}{2} \mathbf{a}^\top \mathbf{a} - x^\top \mathbf{a} + \frac{1}{2} x^\top x < \frac{1}{2} \mathbf{b}^\top \mathbf{b} - x^\top \mathbf{b} + \frac{1}{2} x^\top x \\ &\Leftrightarrow \frac{1}{2} \mathbf{a}^\top \mathbf{a} - x^\top \mathbf{a} < \frac{1}{2} \mathbf{b}^\top \mathbf{b} - x^\top \mathbf{b} \\ &\Leftrightarrow \frac{1}{2} \mathbf{a}^\top \mathbf{a} - x^\top \mathbf{a} - \frac{1}{2} \mathbf{b}^\top \mathbf{b} + x^\top \mathbf{b} < 0 \\ &\Leftrightarrow \frac{1}{2} x^\top \mathbf{b} - x^\top \mathbf{a} - \frac{1}{2} x_0^\top \mathbf{b} + x_0^\top \mathbf{a} < 0 \\ &\Leftrightarrow \langle x, \mathbf{b} - \mathbf{a} \rangle - \langle x_0, \mathbf{b} - \mathbf{a} \rangle < 0 \Leftrightarrow \langle x - x_0, \mathbf{b} - \mathbf{a} \rangle < 0 \end{aligned}$$

是一个半空间, QED

5.3 解 (2)

$$\begin{aligned}\forall x_1 \in \{x | a^T x = b_1\}, x_2 \in \{x | a^T x = b_2\} \\ |b_1 - b_2| = |\langle x_2 - x_1, a \rangle| \leq \|a\|_2 \|x_2 - x_1\|_2 \\ \Leftrightarrow \|x_2 - x_1\|_2 \geq \frac{|b_2 - b_1|}{\|a_2\|_2}\end{aligned}$$

距离是: $\frac{|b_2 - b_1|}{\|a_2\|_2}$

6 HW 6

6.1 问题重述

证明下列函数是凸的。

- (1) 负熵: $f(x) = x \log(x), x > 0$.
- (2) 二次超线性函数: $f(x, y) = \frac{x^2}{y}$ 有 $\text{dom}(f) = \{(x, y) \in \mathbb{R}^2 \mid y > 0\}$.
- (3) $f(\mathbf{x}) = \|A\mathbf{x} - b\|$.
- (4) 支持函数: $S_C(\mathbf{x}) = \sup_{\mathbf{b} \in C} \mathbf{b}^T \mathbf{x}$.
- (5) 点 \mathbf{x} 到集合 $S \subset \mathbb{R}^n$ 的距离 $d(\mathbf{x}, S) = \inf_{\mathbf{b} \in S} \|\mathbf{x} - \mathbf{b}\|$.

6.2 证明 (1)

$$\nabla f(x) = \log(x) + 1 \tag{1}$$

$$\nabla^2 f(x) = \frac{1}{x} \geq 0 \tag{2}$$

则: $f(x) = x \log(x), x > 0$ 是凸函数

6.3 证明 (2)

$$\begin{aligned}
\nabla f(x, y) &= \begin{bmatrix} \frac{2x}{y} \\ -\frac{x^2}{y^2} \end{bmatrix} \quad \forall (x_1, y_1), (x_2, y_2) \in \text{dom}(f) \\
& x_1^2 y_2^2 + x_2^2 y_1^2 - 2x_1 x_2 y_1 y_2 \geq 0 \\
& \Leftrightarrow \frac{x_1 y_2}{x_2^2 y_1^2} (2x_2 y_1 - x_1 y_2) \leq 1 \\
& \Leftrightarrow \frac{x_1}{y_1} \left(\frac{2x_2 y_1 - x_1 y_2}{y_1} \right) \leq \frac{x_2^2}{y_2} \\
& \Leftrightarrow \frac{x_1^2}{y_1} + \frac{x_1}{y_1} \left(2x_2 - 2x_1 - \frac{x_1}{y_1(y_2 - y_1 - 1)} \right) \leq f(x_2, y_2) \\
& \Leftrightarrow f(x_1, y_2) + \left(\frac{2x_1}{y_1}, \frac{-x_1^2}{y_1} \right) \begin{pmatrix} x_2 - x_1 \\ y_2 - y_1 \end{pmatrix} \leq f(x_2, y_2) \\
& \Leftrightarrow f(x_2, y_2) \geq f(x_1, y_1) + \langle \nabla f(x), (x_2, y_2) - (x_1, y_1) \rangle
\end{aligned}$$

因此, $f(x, y)$ 是凸函数得证

6.4 证明 (3)

由通用公式, 令 $z = Ax$, 则 $G(z) = \|z - b\|_2$, $\nabla G(z) = \frac{z-b}{\|z-b\|_2}$, $\nabla f(x) = A^T \frac{Ax-b}{\|Ax-b\|_2}$
 则 Hessian 矩阵:

$$\begin{aligned}
\frac{\partial \nabla f(x)}{\partial x} &= A^T \frac{\partial}{\partial x} \frac{Ax - b}{\|Ax - b\|_2} \\
&= A^T \text{diag} \left(\frac{\|Ax - b\|_2^2 - (a_1^T x - b)(a_1^T x - b)^T}{\|Ax - b\|_2^3}, \dots, \frac{\|Ax - b\|_2^2 - (a_n^T x - b)(a_n^T x - b)^T}{\|Ax - b\|_2^3} \right) A
\end{aligned}$$

显然 $\nabla^2 f(x)$ 是半正定阵, 则 $\|\nabla^2 f(x)\|_2 \geq 0$ 成立, 得证

6.5 证明 (4)

设函数 $f(x, b_i) = b_i^T x$, $b(i) \in C$. 显然: $f(x, b_i)$ 是凸函数.
 则 $\text{epi}(f(x, b_i))$ 是凸集合。
 则: $\bigcap_{b_i \in C} \text{epi}(f(x, b_i)) = \text{epi}(f(x)) = \text{epi}(\max_{b_i \in C} f(x, b_i))$ 是凸集合。
 其中: $f(x) = \sup_{b \in C} b^T x = S_c(x)$
 可知: $f(x)$ 是凸函数, 也就是 $S_c(x)$ 是凸函数

6.6 证明 (5)

设: $f(x, b) = \|x - b\|$
 对 $\forall \epsilon \geq 0, \forall x_i \in \text{dom}(f(x, b)), i = 1, 2, \exists b_i, i = 1, 2$ 满足:

$$f(x_i, b_i) \leq d(x_i, s) + \epsilon$$

$$d(\theta x_1 + (1 - \theta)x_2, s) = \inf_{b \in S} f(\theta x_1 + (1 - \theta)x_2, b) \leq f(\theta x_1 + (1 - \theta)x_2, \theta b_1 + (1 - \theta)b_2) \leq \theta f(x_1, b_1) + (1 - \theta)f(x_2, b_2)$$

其中令: $\epsilon = \max(\theta\epsilon_1, (1 - \theta)\epsilon_2) \rightarrow 0$

7 HW 7

7.1 问题重述

$$\text{已知 } A = U\Sigma V = \begin{bmatrix} -0.91 & 0.37 & -0.18 \\ 0.19 & 0.78 & 0.59 \\ 0.36 & 0.50 & -0.78 \end{bmatrix} \begin{bmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 0.25 & -0.73 & -0.62 \\ -0.74 & -0.56 & 0.35 \\ -0.61 & 0.37 & -0.69 \end{bmatrix}$$

且 $\mathbf{b} = (-0.29, -2.09, -0.98)^\top$ 然后求解 LS 问题:

$$\min_{\mathbf{x}} \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|^2$$

* 通过回溯线搜索实现梯度下降算法, 以解决 LS 问题。

* 为 β -平滑函数实现梯度下降, 以解决 LS 问题。

* 比较不同 A 的收敛速度。

$$A_1 = \begin{bmatrix} -0.91 & 0.37 & -0.18 \\ 0.19 & 0.78 & 0.59 \\ 0.36 & 0.50 & -0.78 \end{bmatrix} \begin{bmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 10^{-2} \end{bmatrix} \begin{bmatrix} 0.25 & -0.73 & -0.62 \\ -0.74 & -0.56 & 0.35 \\ -0.61 & 0.37 & -0.69 \end{bmatrix}$$

and

$$A_2 = \begin{bmatrix} -0.91 & 0.37 & -0.18 \\ 0.19 & 0.78 & 0.59 \\ 0.36 & 0.50 & -0.78 \end{bmatrix} \begin{bmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 10^{-6} \end{bmatrix} \begin{bmatrix} 0.25 & -0.73 & -0.62 \\ -0.74 & -0.56 & 0.35 \\ -0.61 & 0.37 & -0.69 \end{bmatrix}$$

7.2 求解过程

代码及完整运行结果见附页, 运行结果如下:

第一种情况下, 两种算法在迭代次数、时间和运行结果上相差不大, 相对残差都比较小

β 法相对残差、迭代次数及时间: {'迭代次数': 21, '相对残差': 0.1779828155123108}
Wall time: 9.98 ms

参考文献